

Лекция 2. Методы линейной регрессии с разными градиентными спусками

1. Градиент MSE

Градиент:

$$\nabla_{\mathbf{w}} Q(\mathbf{w}_k) = \frac{2}{\ell} X^T (X \mathbf{w}_k - \mathbf{y})$$

Шаг обучения:

$$\eta_k = \lambda \left(\frac{s_0}{s_0 + k} \right)^p$$

Линейная регрессия:

$$\hat{\mathbf{y}} = X \mathbf{w}$$

Обновление весов:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta_k \nabla_{\mathbf{w}} Q(\mathbf{w}_k)$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta_k \frac{2}{\ell} X^T (X \mathbf{w}_k - \mathbf{y})$$

2. Vanilla Gradient Descent

Градиент:

$$\nabla_{\mathbf{w}} Q(\mathbf{w}_k) = \frac{2}{\ell} X^T (X \mathbf{w}_k - \mathbf{y})$$

Шаг обучения:

$$\eta_k = \lambda \left(\frac{s_0}{s_0 + k} \right)^p$$

где

$$s_0 = 1, \quad p = 0.5$$

Линейная регрессия:

$$\hat{\mathbf{y}} = X \mathbf{w}$$

Обновление весов:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta_k \nabla_{\mathbf{w}} Q(\mathbf{w}_k)$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \lambda \left(\frac{s_0}{s_0 + k} \right)^p \frac{2}{\ell} X^T (X \mathbf{w}_k - \mathbf{y})$$

3. Stochastic Gradient Descent

Градиент по случайному батчу B_k :

$$\nabla_{\mathbf{w}} Q_{B_k}(\mathbf{w}_k) = \frac{2}{|B_k|} X_{B_k}^T (X_{B_k} \mathbf{w}_k - \mathbf{y}_{B_k})$$

Шаг обучения:

$$\eta_k = \lambda \left(\frac{s_0}{s_0 + k} \right)^p$$

Линейная регрессия:

$$\hat{\mathbf{y}}_{B_k} = X_{B_k} \mathbf{w}_k.$$

Обновление весов линейной регрессии:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta_k \frac{2}{|B_k|} X_{B_k}^T (X_{B_k} \mathbf{w}_k - \mathbf{y}_{B_k})$$

или с учетом TimeDecayLR:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \lambda \left(\frac{s_0}{s_0 + k} \right)^p \frac{2}{|B_k|} X_{B_k}^T (X_{B_k} \mathbf{w}_k - \mathbf{y}_{B_k})$$

4. SAGDescent

Индивидуальный градиент для i -го объекта:

$$g_i(\mathbf{w}_k) = 2 (\mathbf{x}_i^T \mathbf{w}_k - y_i) \mathbf{x}_i$$

Средний сохранённый градиент:

$$\bar{\mathbf{g}}_k = \frac{1}{n} \sum_{i=1}^n \mathbf{g}_i$$

При пересчёте градиента выбранного объекта j средний градиент обновляется:

$$\bar{\mathbf{g}}_{k+1} = \bar{\mathbf{g}}_k + \frac{1}{n} (\mathbf{g}_j^{new} - \mathbf{g}_j^{old})$$

Шаг обучения:

$$\eta_k = \lambda \left(\frac{s_0}{s_0 + k} \right)^p$$

Линейная регрессия:

$$\hat{\mathbf{y}} = X \mathbf{w}.$$

Обновление весов линейной регрессии:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta_k \bar{\mathbf{g}}_{k+1}$$

или с учетом TimeDecayLR:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \lambda \left(\frac{s_0}{s_0 + k} \right)^p \bar{\mathbf{g}}_{k+1}$$

5. MomentumDescent

Градиент MSE:

$$\nabla_{\mathbf{w}} Q(\mathbf{w}_k) = \frac{2}{n} X^T (X \mathbf{w}_k - \mathbf{y})$$

Шаг обучения:

$$\eta_k = \lambda \left(\frac{s_0}{s_0 + k} \right)^p$$

Накопление импульса:

$$\mathbf{h}_{k+1} = \alpha \mathbf{h}_k + \eta_k \nabla_{\mathbf{w}} Q(\mathbf{w}_k)$$

где

$$\mathbf{h}_0 = 0, \quad \alpha = 0.9.$$

Линейная регрессия:

$$\hat{\mathbf{y}} = X \mathbf{w}.$$

Для MSE:

$$\mathbf{h}_{k+1} = 0.9 \mathbf{h}_k + \eta_k \frac{2}{n} X^T (X \mathbf{w}_k - \mathbf{y})$$

Обновление весов линейной регрессии:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \mathbf{h}_{k+1}$$

или с учетом TimeDecayLR:

$$\mathbf{h}_{k+1} = 0.9 \mathbf{h}_k + \lambda \left(\frac{s_0}{s_0 + k} \right)^p \frac{2}{n} X^T (X \mathbf{w}_k - \mathbf{y})$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \mathbf{h}_{k+1}$$

6. Adam

Начальные значения моментов:

$$\mathbf{m}_0 = \mathbf{0}, \quad \mathbf{v}_0 = \mathbf{0}$$

Градиент MSE:

$$\mathbf{g}_k = \nabla_{\mathbf{w}} Q(\mathbf{w}_k) = \frac{2}{n} X^T (X \mathbf{w}_k - \mathbf{y})$$

Шаг обучения:

$$\eta_k = \lambda \left(\frac{s_0}{s_0 + k} \right)^p$$

Первый момент:

$$\mathbf{m}_{k+1} = \beta_1 \mathbf{m}_k + (1 - \beta_1) \mathbf{g}_k$$

Второй момент:

$$\mathbf{v}_{k+1} = \beta_2 \mathbf{v}_k + (1 - \beta_2) \mathbf{g}_k^2$$

Коррекция первого момента:

$$\hat{\mathbf{m}}_{k+1} = \frac{\mathbf{m}_{k+1}}{1 - \beta_1^{k+1}}$$

Коррекция второго момента:

$$\hat{\mathbf{v}}_{k+1} = \frac{\mathbf{v}_{k+1}}{1 - \beta_2^{k+1}}$$

Параметры метода:

$$\beta_1 = 0.9, \quad \beta_2 = 0.999, \quad \varepsilon = 10^{-8}$$

Линейная регрессия:

$$\hat{\mathbf{y}} = X\mathbf{w}.$$

Обновление весов:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta_k \frac{\hat{\mathbf{m}}_{k+1}}{\sqrt{\hat{\mathbf{v}}_{k+1}} + \varepsilon}$$

С учетом TimeDecayLR:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \lambda \left(\frac{s_0}{s_0 + k} \right)^p \frac{\hat{\mathbf{m}}_{k+1}}{\sqrt{\hat{\mathbf{v}}_{k+1}} + \varepsilon}$$

Алгоритм сравнения методов градиентного спуска и подбор оптимальной длины шага

Необходимо сравнить следующие методы:

VanillaGradientDescent, StochasticGradientDescent, SAGDescent, MomentumDescent, A

Для каждого метода все параметры, кроме начальной длины шага λ , оставить равными значениям по умолчанию.

1. Подбор оптимальной длины шага

Для каждого метода независимо перебираем значения

$$\lambda_1, \lambda_2, \dots, \lambda_m$$

по логарифмической сетке, например

$$\lambda \in \{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1\}.$$

Для каждого значения λ_j :

1. обучаем модель на обучающей выборке; 2. вычисляем ошибку на валидационной выборке;

$$Q_{\text{val}}(\lambda_j) = \frac{1}{\ell_{\text{val}}} \|X_{\text{val}} w(\lambda_j) - y_{\text{val}}\|^2;$$

3. сохраняем полученную ошибку.

Оптимальная длина шага для данного метода определяется как

$$\lambda^* = \underset{\lambda}{\operatorname{argmin}} Q_{\text{val}}(\lambda)$$

То есть лучшим считается то значение λ , при котором ошибка на валидационной выборке минимальна.

Тестовую выборку при выборе λ^* использовать нельзя.

2. Таблица для выбора оптимального λ

Для каждого метода строим таблицу вида

Таблица 1: Сравнение методов градиентного спуска

Метод	λ^*	Loss train	Loss test	R^2_{train}	R^2_{test}	Итерации
Vanilla GD						
SGD						
SAG						
Momentum						
Adam						

Оптимальный шаг выбирается по столбцу

Ошибка validation

как значение λ , соответствующее минимальной ошибке.

3. График для анализа длины шага

Для каждого метода можно построить график

$$Q_{\text{val}}(\lambda)$$

где по оси x :

$$\lambda$$

в логарифмическом масштабе, а по оси y :

$$Q_{\text{val}}.$$

Наилучший шаг соответствует минимуму этого графика:

$$\lambda^* = \underset{\lambda}{\operatorname{argmin}} Q_{\text{val}}(\lambda)$$

Этот график наглядно показывает результат перебора по логарифмической сетке.

4. Итоговое обучение каждого метода

После того как для каждого метода найдено своё оптимальное значение

$$\lambda_{\text{Vanilla}}^*, \quad \lambda_{\text{SGD}}^*, \quad \lambda_{\text{SAG}}^*, \quad \lambda_{\text{Momentum}}^*, \quad \lambda_{\text{Adam}}^*,$$

для каждого метода необходимо сохранить:

$$Q_{\text{train}}, \quad Q_{\text{test}}, \quad R_{\text{train}}^2, \quad R_{\text{test}}^2, \quad N_{\text{iter}}.$$

5. Итоговая таблица сравнения методов

Построить одну таблицу:

Таблица 2: Итоговое сравнение методов градиентного спуска

Метод	Лучшее λ^*	Loss train	Loss test	R_{train}^2	R_{test}^2	Число итераций
VanillaGradientDescent						
StochasticGradientDescent						
SAGDescent						
MomentumDescent						
Adam						

6. График сравнения сходимости методов

Используя для каждого метода уже найденное оптимальное значение λ^* , построить один общий график зависимости

$$Q_{\text{train}}(w_k) \text{ от номера итерации } k$$

для всех пяти методов.

По оси x :

$$k = \text{номер итерации.}$$

По оси y :

$$Q_{\text{train}}(w_k) = \frac{1}{\ell_{\text{train}}} \|X_{\text{train}} w_k - y_{\text{train}}\|^2.$$

На одном графике должны находиться пять кривых:

$$\text{Vanilla GD, \quad SGD, \quad SAG, \quad Momentum, \quad Adam.}$$

7. Как делать итоговый вывод

Лучший λ внутри каждого метода определяется только как

$$\lambda^* = \arg \min_{\lambda} Q_{\text{val}}(\lambda).$$

После выбора оптимального значения λ^* методы сравниваются между собой.

Лучшее качество на новых данных соответствует меньшему значению Q_{test} и большему значению R_{test}^2 .

Скорость сходимости определяется по количеству итераций N_{iter} и по графику зависимости ошибки на обучающей выборке от номера итерации: $Q_{\text{train}}(w_k)$.

Таким образом, итоговое сравнение должно учитывать одновременно качество модели и скорость сходимости.