


Лекция 1. Линейная регрессия

Линейная регрессия предсказывает по характеристикам число, строя линию, максимально близкую к данным. Например: цена на квартиру в зависимости от метража:



Таким образом, линия помогает предсказать примерную цену следующей квартиры.

Теперь научимся обучать модель, т. е. научимся искать уравнение линии, которая описывает закономерность данных. Как нам известно из математики, линия в n -мерном пространстве задается уравнением:

$$y = w_0 + w_1x_1 + \dots + w_nx_n$$

Задача линейной регрессии: найти коэффициенты $w_0, \dots, w_n$ так, чтобы данные y (например, цены на жилье) были максимально близки к линии.

Входные данные в табличном виде будут заданы так:

N^o	x_1	x_2	$\dots$	y
1				
2				
$\dots$				
m				

где x_i — характеристики (метраж, номер этажа, и т. д.), а y — значение (например, цена).

С одной стороны, веса легко можно найти, решив систему уравнений $X \cdot \vec{w} = \vec{y}$; домножаем на X^T :

$$\begin{aligned} \frac{X^T \cdot X \cdot w}{A} &= \frac{X^T y}{b} \\ A \cdot \vec{w} &= b \\ \vec{w} &= A^{-1}b \end{aligned}$$

Однако, это большой вычислительный процесс (долго будет считать). Есть способ в несколько раз быстрее. Он называется методом сопряженных градиентов.

Он задает $w_0, \dots, w_n$ сначала случайными числами, потом на каждом шаге улучшает их:

$$w_i^k = w_i^{k-1} - \eta \cdot \nabla L(w^{k-1})$$

где k — это номер шага, η — размер шага, L — градиент ошибки на шаге $k - 1$.

Формула градиента для шага k :

$$\nabla L(w^k) = \left(\frac{\partial L}{\partial w_1^k}, \dots, \frac{\partial L}{\partial w_n^k} \right)^T$$

где L — это величина ошибки (на каждом шаге конца вычисляется по новой). У неё есть несколько формул, о них поговорим позже.

Сперва я хочу рассказать про sparse-cg, который позволяет не задавать размер шага самостоятельно, а вычислять его оптимальное значение на каждой итерации.

Таким образом, линейная регрессия с применением sparse-cg имеет следующую формулу для вычисления весов:

$$w^{k+1} = w^k + \alpha_k p_k$$

где:

- w^k — текущие веса (на k -м шаге);
- p_k — направление движения;
- α_k — насколько далеко надо пройти в этом направлении;
- $r_k = b - Aw_k$ — невязка;
- $A = X^T X$ (для линейной регрессии).

А теперь я опишу подробно алгоритм линейной регрессии с применением sparse-cg (т. к. этот вид градиентного спуска по результатам исследования является самым быстрым и оптимальным).

Шаг 1

По данным файла (датасета) составляем матрицу характеристик X и вектор правильных ответов y :

$$X = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{pmatrix}, \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

где m — число объектов, n — число характеристик.

Формулу для $\hat{y}$, который будет давать ответы, задаем так:

$$\hat{y} = X \cdot w$$

а для отдельного объекта так:

$$\hat{y}_i = w_1 x_{i1} + \dots + w_n x_{in}$$

Шаг 2

Задаем формулу функции потерь:

$$L(w) = \sum_{i=1}^m (\hat{y}_i - y_i)^2$$

Шаг 3

Для этой ошибки задаем формулу градиента:

$$\nabla L(w) = 2X^T(Xw - y)$$

Шаг 4

Приводим задачу к виду $Aw = b$:

$$A = X^T X, \quad b = X^T y$$

Именно её теперь мы будем решать методом сопряженных градиентов.

Шаг 5

Задаем начальные веса. Например, так:

$$w_0 = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

Шаг 6

Считаем начальную невязку:

$$r_0 = b - Aw_0$$

и начальное направление:

$$p_0 = r_0$$

Шаг 7

Считаем на каждой итерации:

1. длину шага:

$$\alpha_k = \frac{r_k^T \cdot r_k}{p_k^T \cdot X^T \cdot X \cdot p_k}$$

2. новые веса:

$$w_{k+1} = w_k + \alpha_k p_k$$

3. новую невязку:

$$r_{k+1} = r_k - \alpha_k A p_k$$

4. новое направление:

$$p_{k+1} = r_{k+1} + \beta_k \cdot p_k, \quad \text{где } \beta_k = \frac{r_{k+1}^T \cdot r_{k+1}}{r_k^T \cdot r_k}$$

Продолжаем этот шаг повторять пока $\|r_k\| < \varepsilon$.

Шаг 8 (этап тестирования)

1. Считаем по получившимся весам для тестовой выборки:

$$\hat{y}_i = w_0 + w_1 x_{i1} + \dots + w_n x_{in}$$

где:

- $\hat{y}_i$ — ответ для i -го объекта;

- $w_0, \dots, w_n$ — веса, которые мы получили при обучении;
- $x_{i1}, \dots, x_{in}$ — характеристики i -го объекта.

2. Считаем величину ошибки:

$$L(w) = \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

Эта формула ошибки называется SSE.

В питоне sparse-cg вызывается через Ridge в sklearn:

```
from sklearn.linear_model import Ridge
```

```
model = Ridge(alpha=0.0, solver='sparse_cg')
```

```
model.fit(X, y)
```

`alpha = 0.0` говорит о том, что тут нет регуляризации, т. е. о том, что мы обучаем линейную регрессию.